




PROGRAMME
DE RECHERCHE
INTELLIGENCE
ARTIFICIELLE

Beyond Transformers

Usages et limites des LLM pour les systèmes d'IA


Le biais inductif : ce que le modèle *croit* avant même d'apprendre

Tout réseau de neurones encode des hypothèses cachées sur la forme des données




MLP

structure Euclidienne plate



CNN

Grille 2D



Transformers


Séquences

Ce que les LLMs ratent

Les Transformers pondèrent la pertinence de chaque token vis-à-vis de **tous les autres**. Ce mécanisme est équivalent à un réseau de neurones sur graphe entièrement connecté, dont la force des liens est calculée à la volée.

Limites pour le traitement à grande échelle :





- Analyse les données comme des **séquences plates**
- **Fenêtre de contexte limitée** par la complexité quadratique de l'attention
- **Non-déterministes**
- Dépendants d'une **requête**



Beyond Euclid

Dans beaucoup d'applications, les données affichent une notion structurante de **connectivité** (molécules, systèmes connectés, modélisation 3D, réseaux sociaux, bases documentaires).

C'est le postulat de l'analyse de données *à la française* : les données ont une **géométrie**.



Hajij et al. (2022). Topological deep learning: Going beyond graph data. *arXiv preprint arXiv:2206.00606*.


Graphes: sortir de la matrice

Les Graph Neural Network modélisent les données comme des interactions plutôt que des matrices : premier niveau de prise en compte de la connectivité.

Message-passing : à chaque couche du réseau, l'information s'échange entre les voisins.

Mais :

- Les graphes ne prennent en compte que les relations pair-à-pair
- Under-reaching : besoin de beaucoup de couches pour que l'info se propage
- Over-smoothing : à l'échelle, les noeuds partagent la même info




Au-delà des graphes

Réseaux social, corpus de rapports, logs d'incidents... toutes ces données sont **relationnelles** :

- *Groupes de personnes appartenant à la même communauté*
- *Documents écrits par les mêmes auteurs / sur un même sujet*
- *Incidents survenus la même semaine, sur le même périmètre*


Traditional Discrete Domains



○ : Nodes

— : Edges

General Topological Domains




Analyser le social par la topologie

Les modèles d'apprentissage topologique permettent de croiser des degrés de connectivité très élevés : sémantique, temporel, interactions sociales (mentions, co-auteurs, appartenance à des communautés).

Exploration non-supervisée : découverte de groupes et dimensions latentes sur l'ensemble des champs de connectivité

Node-prediction : prédiction de caractéristique sur les points selon leur connectivité


Higher-order prediction : prédiction de liens probables mais encore inexistants dans des corpus de données sociales





Papillon, M., Sanborn, S., Hajij, M., & Miolane, N. (2023). Architectures of topological deep learning: A survey of message-passing topological neural networks. *arXiv preprint arXiv:2304.10031*.

Analyser le social par la topologie

Hypergraph
data representation




Topological
clustering



Topological Neural Network:
predicting paper authorship

Scaling models toward foundational capabilities



Position: Topological Deep Learning is the New Frontier for Relational Learning

Theodore Papamarkou¹ Tolga Birdal² Michael Bronstein³ Gunnar Carlsson^{4,5} Justin Curry⁶ Yue Gao⁷
Mustafa Hajij⁸ Roland Kritt⁹ Pietro Liò¹⁰ Paolo Di Lorenzo¹¹ Vasileios Maroulas¹² Nina Miolane¹³
Farzana Nasrin¹⁴ Karthikeyan Natesan Ramamurthy¹⁵ Bastian Rieck^{16,17} Simone Scardapane¹¹
Michael T. Schaub¹⁸ Petar Veličković^{19,10} Bei Wang²⁰ Yusu Wang²¹ Guo-Wei Wei²² Ghada Zamzmi²³

Abstract

Topological deep learning (TDL) is a rapidly evolving field that uses topological features to understand and design deep learning models. This paper posits that TDL is the new frontier for relational learning. TDL may complement graph representation learning and geometric deep learning by incorporating topological concepts, and can thus provide a natural choice for various machine learning settings. To this end, this paper discusses open problems in TDL, ranging from practical benefits to theoretical foundations. For each problem, it outlines potential solutions and future research opportunities. At the same time, this paper serves as an invitation to the scientific community to actively participate in TDL research to unlock the potential of this emerging field.

1. Introduction

Traditional machine learning often assumes that the observed data of interest are supported on a linear vector space and can be described by a set of feature vectors. However, there is growing awareness that, in many cases, this viewpoint is insufficient to describe several data within the real world. For example, molecules may be described more appropriately by graphs than feature vectors. Other examples include three-dimensional objects represented by meshes, as encountered in computer graphics and geometry processing, or data supported on top of a complex social network of interrelated actors. Hence, there has been an increased interest in importing concepts from geometry and topology into the usual machine learning pipelines to gain further insights into such types of data in a systematic way.

One of the most prominent examples of this research direction is geometric deep learning (GDL); see (Bronstein et al., 2021; Zhou et al., 2020; Wu et al., 2020; Nguyen &

Hoffmann, J., Borgeaud, S., Mensch, A., Buchatskaya, E., Cai, T., Rutherford, E., ... & Sifre, L. (2022). Training compute-optimal large language models. *arXiv preprint arXiv:2203.15556*, 10.



PROGRAMME
DE RECHERCHE

INTELLIGENCE
ARTIFICIELLE

Merci !

Contact : antoine@arlq.ai

